E-commerce 데이터를 활용한 데이터 분석 심화 과정

강사: 김현준

목차

1. 탐색적 데이터 분석(EDA) 및 데이터 전처리
    a. 분석 과정 이전에 데이터의 특징을 확인하고 전처리 하는 과정
2. 데이터 심화 분석
    a. 퍼널 분석, 코호트 분석, 군집화(clustering) 등의 분석
    b. 가설을 세우고 통계적 가설 검정을 수행
3. 데이터 시각화와 리포트 작성
    a. Looker Studio를 활용한 리포트 작성

들어가기에 앞서

이번 강의에서는 python을 주로 다룰 예정이며, 중간중간에 필요한 SQL 문법을 언급

- 데이터 분석가가 꼭 알아둬야 할 언어들
  - SQL은 필수, R과 python 중 택 1
- 회사 내 데이터 베이스로부터 원하는 데이터를 추출할 때 SQL 사용
  - **생각보다 SQL을 사용해야 하는 빈도가 높음**
- 추출한 데이터로 분석을 할 때 R 혹은 python 사용
- ML, 특히 딥러닝에는 python이 편리하기 때문에 python의 사용 빈도가 증가하고 있음
  - Pytorch, tensorflow 등의 딥러닝 프레임워크 지원

활용 데이터셋

- Looker Ecommerce BigQuery dataset
  - 구글에서 제공한 데이터셋
  - 빅쿼리에서도 탐색 가능
- 구매 정보, 유저/상품의 세부 데이터
  - 실제 업무에서 자주 활용되는 데이터 형식
- 유저 행동 분석, 구매 패턴 분석 등에 활용 가능

심화 데이터 분석

퍼널 분석

- 고객의 여정을 단계별로 추적하고 분석하는 방법
- ‘Funnel’은 깔때기라는 의미로 고객의 여정 단계별로 유저 수가 줄어드는 모습이 비슷하기 때문
- 다양한 상황에서 활용할 수 있음
  - 서비스 런칭 직후에는 접속 관련 이슈 파악
  - 이후에는 각 단계별 이탈율 파악 및 개선 필요 지점 파악
- 전체 유저의 경향성을 파악하고 세부 세그먼트 순으로 파악하는 과정이 필요
  - 향후 진행하는 데이터 분석 방법론 공통 사항

리텐션 분석

- 유저가 계속해서 제품에 남는 비율
  - (N일 후 접속한 유저 수) / (해당 일 접속 유저 수)
  - 접속 뿐만 아니라 구매, 시청 등의 다양한 지표를 활용 가능
- 대부분의 상황에서 신규 고객 유치 비용 > 기존 유저 잔존 비용
- 따라서 잔존율을 높이는 것이 장기적으로 어떤 제품에서든지 중요한 사항
  - **“Retention is King”**
- 퍼널이 유저의 유입을 위한 분석이라면 리텐션은 유저를 남게 하기 위한 지표

코호트

- 코호트: 특정 기간 동안 공통된 특성이나 경험을 갖는 사용자 집단
  - 특정 기간이라는 조건이 붙음
- 다양한 기준으로 코호트를 분류할 수 있음
- 보통 대부분은 신규 가입 일자를 기준으로 코호트를 분류
  - ex) 3월 신규 가입자, 4월 신규 가입자
  - 해당 기간 가입 유저의 특성을 파악할 수 있음
- 각 코호트들의 지표(전환율, 구매액, 리텐션)의 추이를 보며 전략 설정 가능

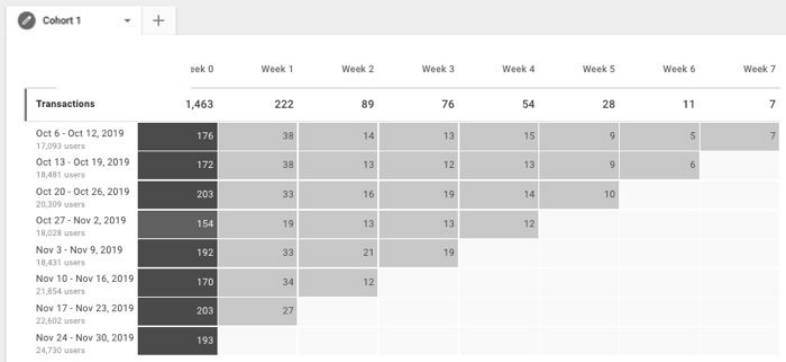

Cohort 1

	ek 0	Week 1	Week 2	Week 3	Week 4	Week 5	Week 6	Week 7
Transactions	1,463	222	89	76	54	28	11	7
Oct 6 - Oct 12, 2019 17,093 users	176	38	14	13	15	9	5	7
Oct 13 - Oct 19, 2019 18,481 users	172	38	13	12	13	9	6	
Oct 20 - Oct 26, 2019 20,309 users	203	33	16	19	14	10		
Oct 27 - Nov 2, 2019 18,028 users	154	19	13	13	12			
Nov 3 - Nov 9, 2019 18,431 users	192	33	21	19				
Nov 10 - Nov 16, 2019 21,854 users	170	34	12					
Nov 17 - Nov 23, 2019 22,602 users	203	27						
Nov 24 - Nov 30, 2019 24,730 users	193							

클러스터링

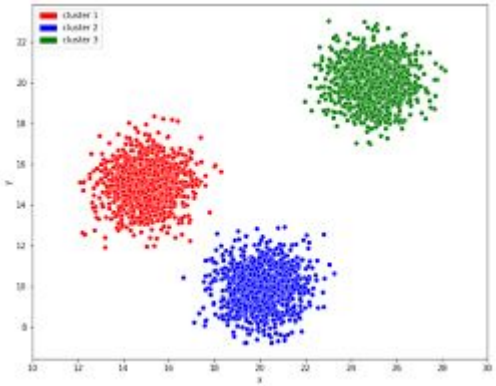

- 레이블이 지정되어 있지 않은 데이터를 그룹핑하는 분석 알고리즘
  - 클러스터: 비슷한 특성을 가진 데이터 집합
- 현업에서는 유저들의 특성에 따라 클러스터링 하는 경우가 많음
  - ex) 헤비/라이트 유저, 고과금/저과금 유저
- 유저 그룹의 변화 추이를 보고 의사결정을 하거나 그룹 대상으로 이벤트, 프로모션 진행 가능
- 단일 변수 사용 시에는 rule 기반으로 할 수 있지만 다변수 사용시에는 머신러닝 알고리즘이 편함
  - 여러 변수를 N개 혹은 X 이상의 밀집도를 가진 집단으로 분류
  - 클러스터링은 대표적인 ‘비지도학습’ 알고리즘
    - 정답 레이블 없이 학습

K-means

- 가장 대표적인 클러스터링 알고리즘으로 K개의 군집을 생성
  - 군집의 크기는 사용자가 정해줘야 함
- 집단 내 데이터들은 비슷한 특징을 가지고 있고 다른 집단 데이터들과는 다른 특징을 가지고 있을 것이란 가정 하에 진행
- 간단하고 해석이 쉬우며 성능이 좋음
- 그러나 cluster의 개수를 미리 지정해야 하며 구형 데이터가 아니면 성능이 하락
- 그럼에도 불구하고 사용하기 쉽고 성능이 좋아 클러스터링에 자주 사용되는 알고리즘

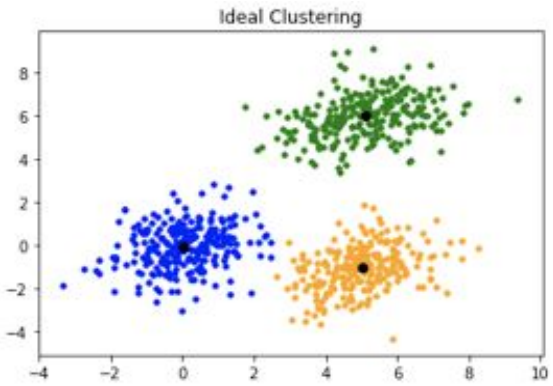

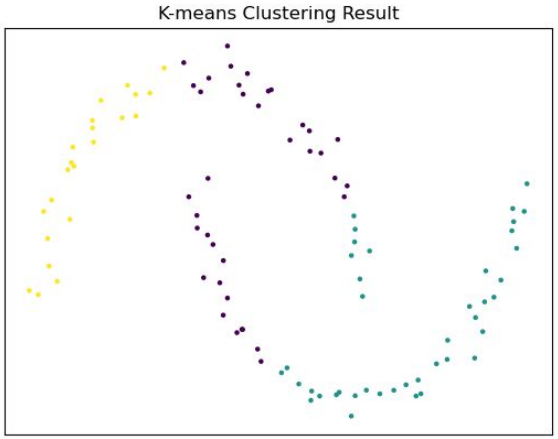

가설 검정

- 모집단의 특성에 대한 가설을 설정한 뒤에 표본 관찰을 통하여 그 가설의 채택 여부를 결정하는 통계적 분석 방법
- 증명되지 않은 가설을 표본에 대한 관찰을 통해 입증
- 현업에서는 매일 다양한 가설을 설정하고 실험을 진행함
  - A/B test
  - ex) 푸시 알람에 정확한 혜택 금액을 넣으면 클릭율이 증가할 것이다
- **실험 과정을 잘 설계**하고 **결과를 정확히 해석하도록 돕는 것**이 데이터 분석가의 주요 업무 중 하나

가설 검정

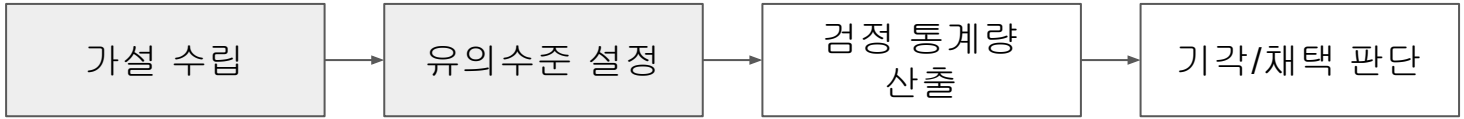

- 가설 수립
  - 귀무 가설: 기존의 주장이나 일반적으로 받아들여지는 가설.
  - 대립 가설: 귀무 가설과 반대되는 주장. 연구자가 입증하고자 하는 가설
- 유의 수준 설정
  - 귀무가설을 기각할 때 허용되는 제1종 오류의 최대 확률
    - 제 1종 오류: 귀무가설이 참인데 기각할 확률
  - 일반적으로 0.05, 0.01을 사용하며 도메인과 분석 목적에 따라 변경

가설 검정

가설 수립 → 유의수준 설정 → 검정 통계량 산출 → 기각/채택 판단
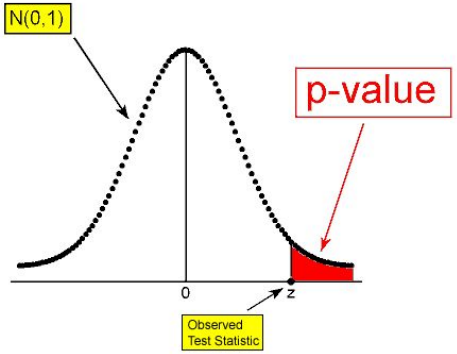
- 검정 통계량
  - 가설 검정 시 사용하는 표본 통계량
  - 어떤 검정을 진행하느냐에 따라 다른 값을 계산
    - 평균 차이 검정: Z-값, t-값 / 그룹별 비율 차이 검정: 카이제곱-값 등
- P-value 도출
  - 귀무 가설이 참일 때, 관측된 결과보다 더 극단적인 결과가 나올 확률
  - 단측 검정의 경우, (1 - 검정 통계량까지의 누적 분포함수)
  - 기존에 설정한 유의 수준보다 작으면 귀무가설 기각
- 위에서 도출한 p-value를 바탕으로 귀무가설 채택 여부 결정