고객 행동 및 결제 데이터 분석을 통한

프로덕트 개선

2차시 : 작업 환경 셋팅 및 탐색적 데이터 분석 학습

Product Data Analyst NY

1차시 과제 Review

<왜 데이터 분석을 배우고 싶나요?>

데이터 분석을 배우려는 이유 혹은 데이터 분석가가 되려는 이유를 담아 1분 자기소개를 준비해 주세요.

8차시 수업을 함께할 강사와 동료들과 싱크를 맞추고, 앞으로 달려나가기 위한 목표를 단단히 세워보아요.

과제 마감 기한 : 다음 수업 3시간 이전까지 제출 (환급 기준)

1. 김승민님

2. 김송하님

4. 이현정님

5. 장하나님

6. 장준영님

7. 박양하님

Hello!
MY Name is
Yangha Park.

해 본 직업 (요약)

- 자동차 렌탈 사무
- 경영 지원 사무
- 생산 관리 과장
- 배터리팩 제조 파트장
- 배터리 공정기술 엔지니어

전공

- 이탈리아어
- 경영학
- 소셜미디어 마케팅

제목: 자화상

Battery Energy Storage System

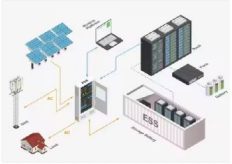

T의 대화 수단:
데이터 그리고 증거

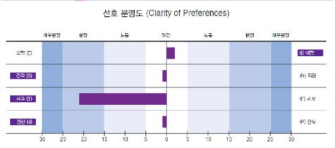

회사에서
(데이터, 숫자 집착 환자)

집에서
(활동 기록, 음식 및 시간 관리)

7. 박양하님

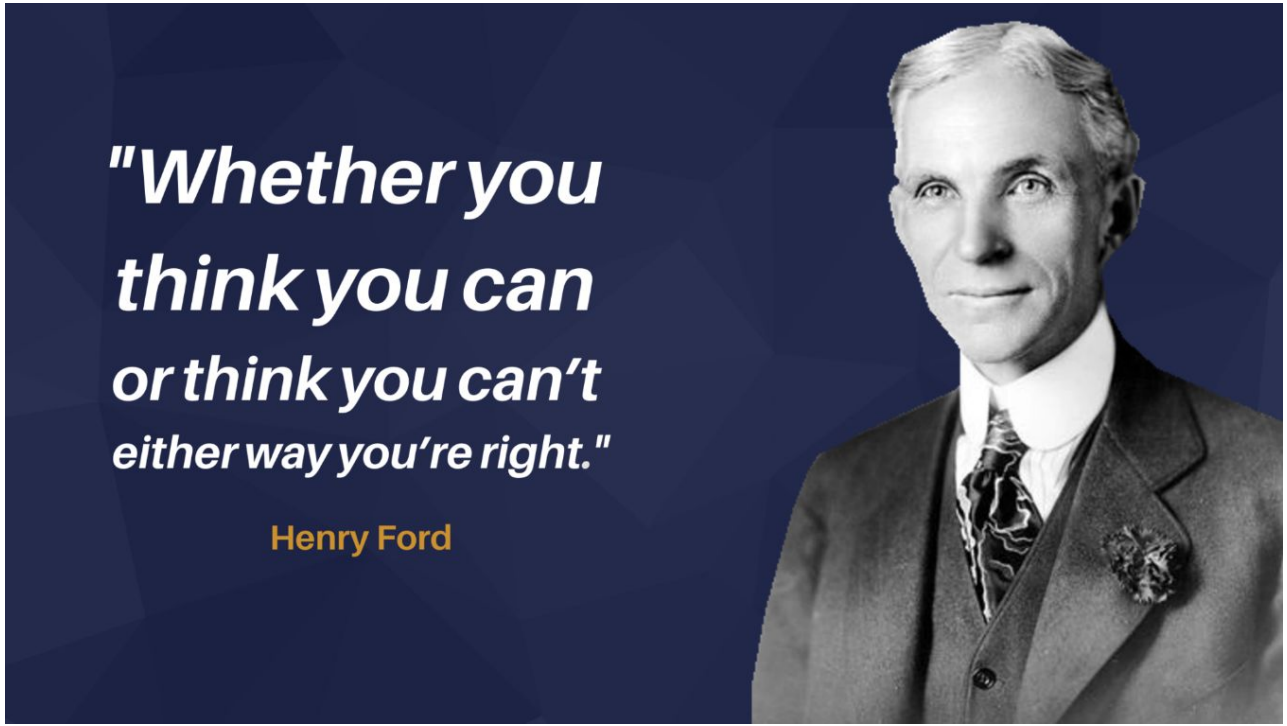
"Whether you
think you can
or think you can't
either way you're right."
Henry Ford

1. 작업 환경 셋팅

사용 데이터

1) 프로덕트 결제, 유저 행동 로그 데이터
2) 마케팅 캠페인 - 메세지 발송 데이터

실습 환경

Google Bigquery, Google Colab, Google Spreadsheet

학습 언어

SQL (Main) , Python

1.1. Google Big Query

Big Query?

- 데이터를 분석할 수 있는 Data Warehouse를 클라우드 기반으로 간단하게 구축 가능
- Google ID로 사용 가능하며, Google Product 간 확장성이 좋음(스프레드시트 데이터 연결 등)
- 신규 90일 무료체험 가능(300달러 크레딧, 매월 10GB 스토리지, 최대 1TB 쿼리)

Big Query

Data Warehouse

Spreadsheet

Colab

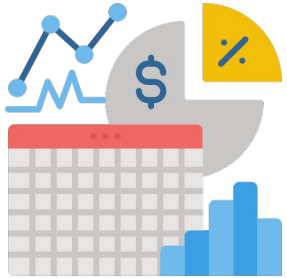

1.1. Google Big Query

1) 분석 프로젝트 생성하기

https://console.cloud.google.com/bigquery

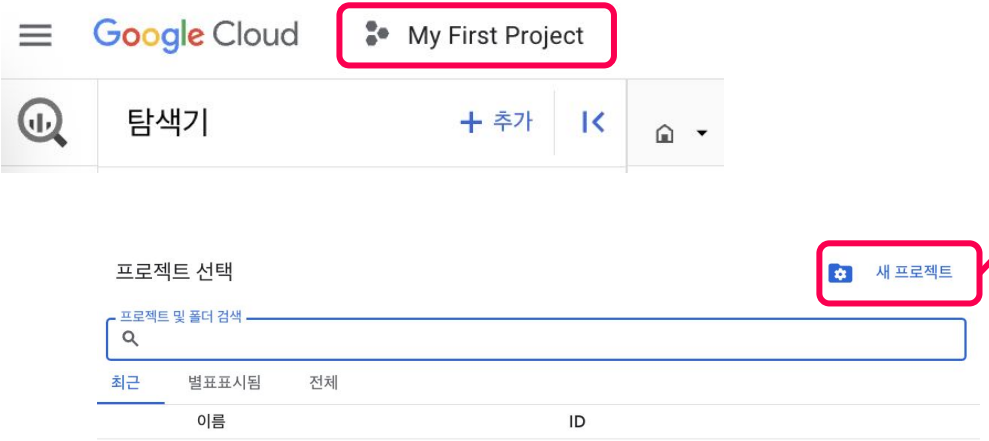

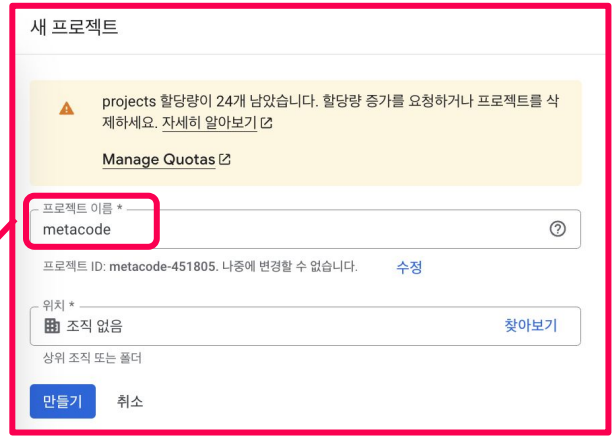

*무료 프로젝트에서는 데이터가 60일 후 삭제되니 연습용으로 사용하고 필요시 백업하세요!

1.1. Google Big Query

2) CSV 데이터로 테이블 생성하기

1. 데이터 세트 만들기

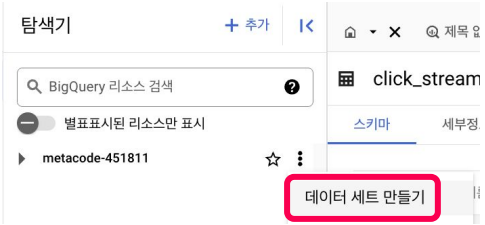

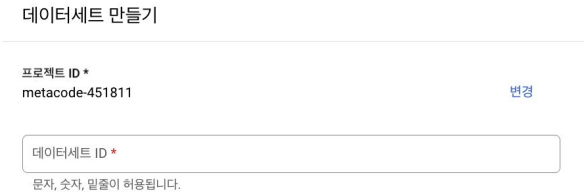

2. 탐색기 영역 > [추가] 버튼 클릭

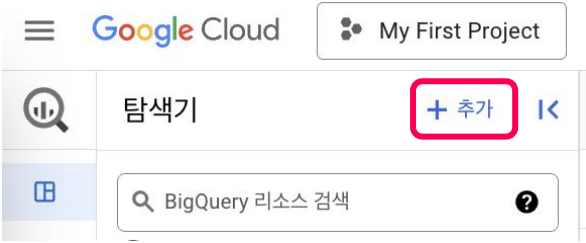

3. 로컬파일 업로드 클릭

1.1. Google Big Query

2) CSV 데이터로 테이블 생성하기

4. 테이블 만들기

   a. **소스** 영역
      i. 테이블을 만들 소스 [드라이브] 선택
      ii. **DRIVE URI 입력**
      iii. 파일 형식 [csv] 선택

   b. **대상위치** 영역
      i. 프로젝트, 데이터 세트, 테이블명 작성

   c. **스키마** 영역
      i. 자동감지 체크

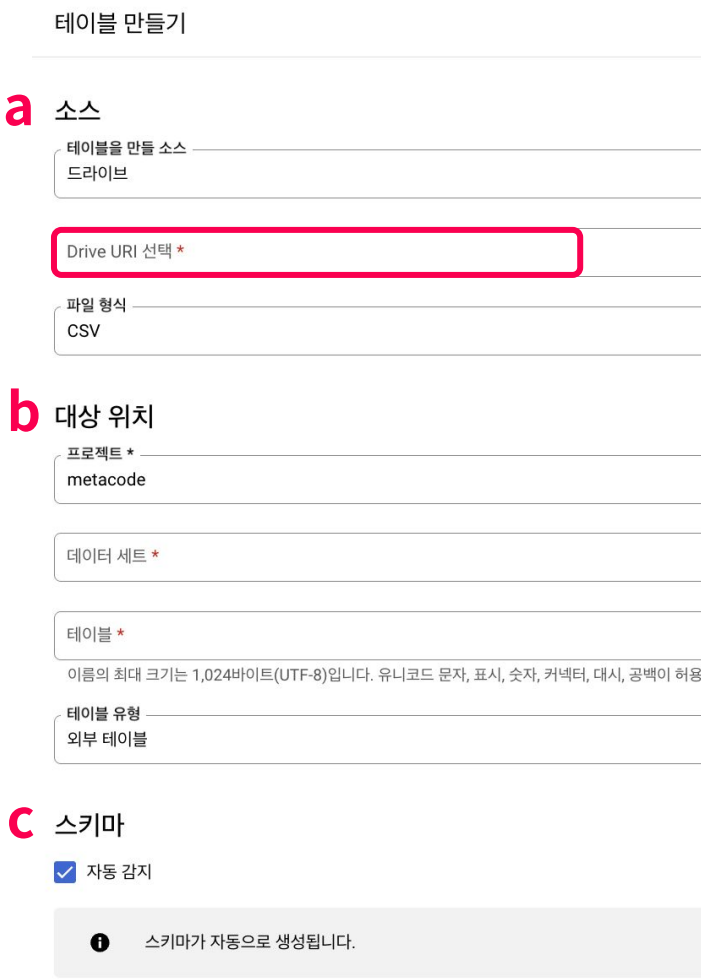

1.1. Google Big Query

2) CSV 데이터로 테이블 생성하기

DRIVE URI
https://drive.google.com/open?id=[file id] 형태

E-Commerce Transaction & Log(Click Stream) Data

click stream : https://drive.google.com/open?id=12NVWbpt86Zv2DujdmWVcLu7k_tcuctrt/
customer : https://drive.google.com/open?id=1OBYNXSAwmE2seEff4KRdNacG-hTCej8O/
product : https://drive.google.com/open?id=1svHx0-qnqBPKR9RKlyFkyp5fPisYzYVa/
transaction : https://drive.google.com/open?id=1gVE9c4PNvL2n_Y2O3bouvhbYFWKxQ25R/

1.1. Google Big Query

3) 스프레드시트 연결해 테이블 생성하기

https://docs.google.com/spreadsheets

데이터 > 데이터 커넥터 > BigQuery에 연결

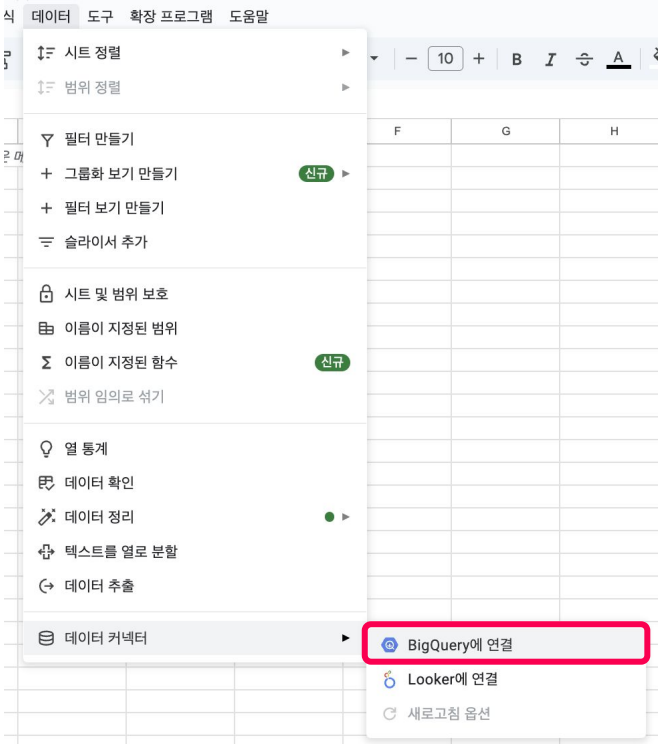

1.2. Google Colab

https://colab.research.google.com/

```
from google.colab import auth
auth.authenticate_user()

!pip install pandas
!pip install pandas-gbq
import pandas as pd
import numpy as np
import pandas_gbq
```

패키지 설치 및 불러오기

```
project_id = '프로젝트id'
query = '''
select count(*) from 테이블명
'''
```

불러올 쿼리 작성

```
df = pandas_gbq.read_gbq(query, project_id = project_id, dialect="standard", use_bqstorage_api=True)
```

https://cloud.google.com/bigquery/docs/samples/bigquery-pandas-gbq-read-gbq-simple?hl=ko
pandas 관련 공식 문서 : https://pandas.pydata.org/docs/reference/api/pandas.read_gbq.html

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.1. EDA 개괄

- 탐색적 데이터 분석(Exploratory Data Analysis)은 데이터를 시각화하고 통계적 방법을 사용하여 데이터의 주요 특징을 이해하는 과정입니다.
- **데이터의 구조, 분포, 관계를 파악**하고 **분석의 방향성을 설정**하기 위해 EDA를 진행합니다.

EDA를 하는 이유

- 데이터에서 숨겨진 패턴, 이상치(outliers), 결측치(missing values)를 발견할 수 있습니다.
- 데이터 분석의 방향성을 설정하고, 가설을 세울 수 있게 도와줍니다.
- 모델링 전에 데이터의 특성을 이해하여 더 나은 모델을 구축할 수 있습니다.

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.2. 데이터 전처리

1. **데이터 구조 파악**

   - 테이블 요약 정보 확인

2. **결측치, 이상치 확인**

   - 결측치(null, na, ‘’)
   - 이상치(Outlier)

3. **(필요시) 데이터 정제**

- Python **Pandas** library 사용 시 데이터 핸들링을 쉽게 할 수 있습니다.

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.3. 기초 통계 분석

- **범주형 데이터 vs 연속형 데이터**

범주형 데이터(Categorical Data)	연속형 데이터(Continuous Data)
명목형 데이터(Nominal Data) - 자료 간 순서가 없는 데이터 - 단위 당 발생 **빈도**를 확인 - ex. **카테고리** 별 매출	- 연속적인 스케일을 가지는 데이터 - **분포** 및 **비율**을 확인 - ex. 날짜, 나이, 키, 온도, 판매량, 매출 - 필요시 특정 구간을 묶어 범주화 가능 나이 > 연령대(10대, 20대, …) 온도 > 영하, 0도, 영상
순서형 데이터(Ordinal Data) - 순서가 있는 데이터 - 순위 혹은 상대적 비교 - ex. 고객 만족도(매우 불만족, 불만족, 보통, 만족, 매우 만족)	- **통계량(평균, 중앙값, 분산, 표준편차)** 확인 가능 - **통계 분석 기법(상관 분석, 회귀 분석)** 사용 가능

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.3. 기초 통계 분석

- **범주형 데이터**

  발생 빈도 확인

- **연속형 데이터**

  통계량 확인

  평균, 중앙값, 분산, 표준편차 등

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.4. 데이터 시각화 - 유형별

- **범주형 데이터**

  막대 그래프(Bar Plot)

  파이 차트(Pie Chart)

- **연속형 데이터**

  선 차트(Line Chart)

  히스토그램(Histogram)

  박스플롯(Box Plot)

  산점도(Scatter Plot)

  히트맵(Heatmap)

2. 탐색적 데이터 분석
(EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- 막대 그래프(Bar Plot)

  파이 차트(Pie Chart)

  범주형 데이터 집계 확인

2. 탐색적 데이터 분석
(EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- **선 차트(Line Chart)**

  시계열(Time series) 데이터 분포 확인

  ex. 월간 판매량 증가 추이

2. 탐색적 데이터 분석
(EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- **히스토그램(Histogram)**

  도수분포표*를 시각화

  데이터를 일정한 구간으로 나누고 구간별 빈도를 표기

  ex. 연령별 고객 수

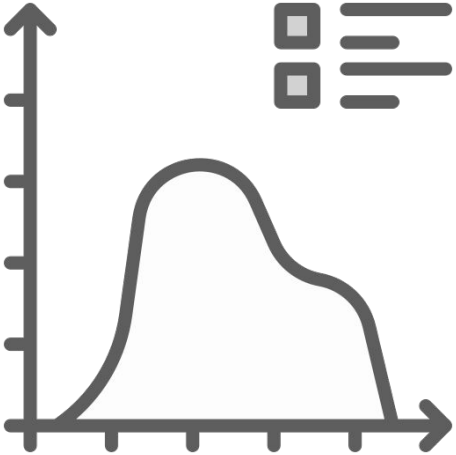

*특정 그룹이나 주기 안에 값이 발생한 빈도나 횟수 등의 표본 값 분포를 요약한 표

2. 탐색적 데이터 분석 (EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- **박스 플롯(Box Plot)**

  데이터 분포와 이상치 확인

  ** 참고(Wikipedia)*

  - 중위수
    : 데이터의 정 가운데 순위에 해당하는 값
  - 제 3사분위 수 (Q3)
    : 중앙값 기준으로 상위 50% 중의 중앙값, 전체 중 상위 25%
  - 제 1사분위 수 (Q1)
    : 중앙값 기준으로 하위 50% 중의 중앙값, 전체 중 하위 25%
  - 사분위 범위 수(IQR)
    : 데이터의 중간 50% (Q3 - Q1)

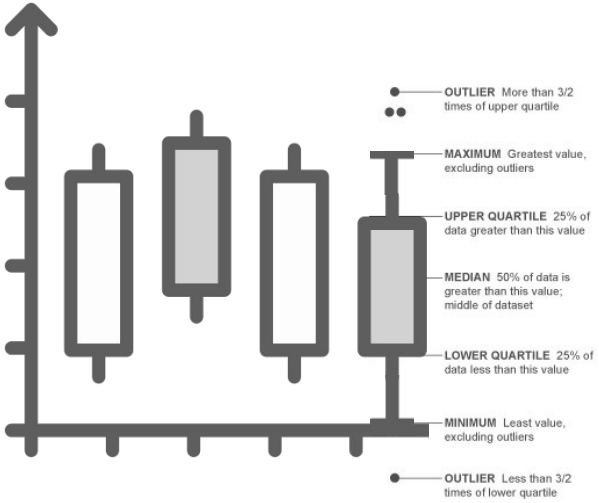

2. 탐색적 데이터 분석
(EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- **산점도(Scatter Plot)**

  X, Y 두 변수 간의 관계 확인

  ex. X와 Y간 양(+)의 상관관계가 있다

  > X와 Y는 같은 방향으로 움직이는 변수이다.

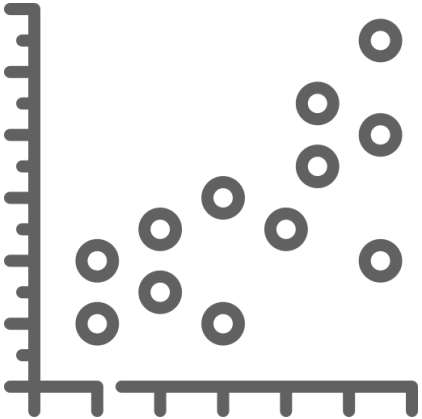

2. 탐색적 데이터 분석
(EDA, Exploratory Data Analysis)

2.4. 데이터 시각화

- **히트맵(Heatmap)**

  변수들 간의 상관관계(공분산, Covariance) 확인

  ex. 옆 예시

  > 크기가 클수록 상관관계가 높은 변수이다.

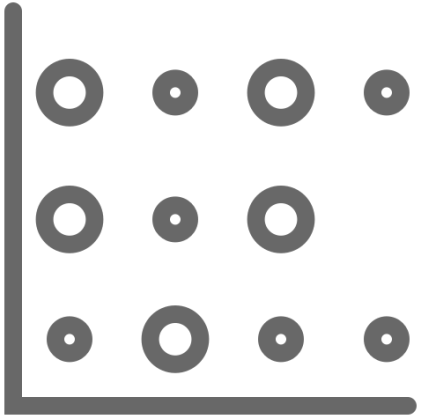

3. 분석할 데이터셋 간단히 살펴보기

E-Commerce Transaction & Log(Click Stream) Data

3.1. ERD

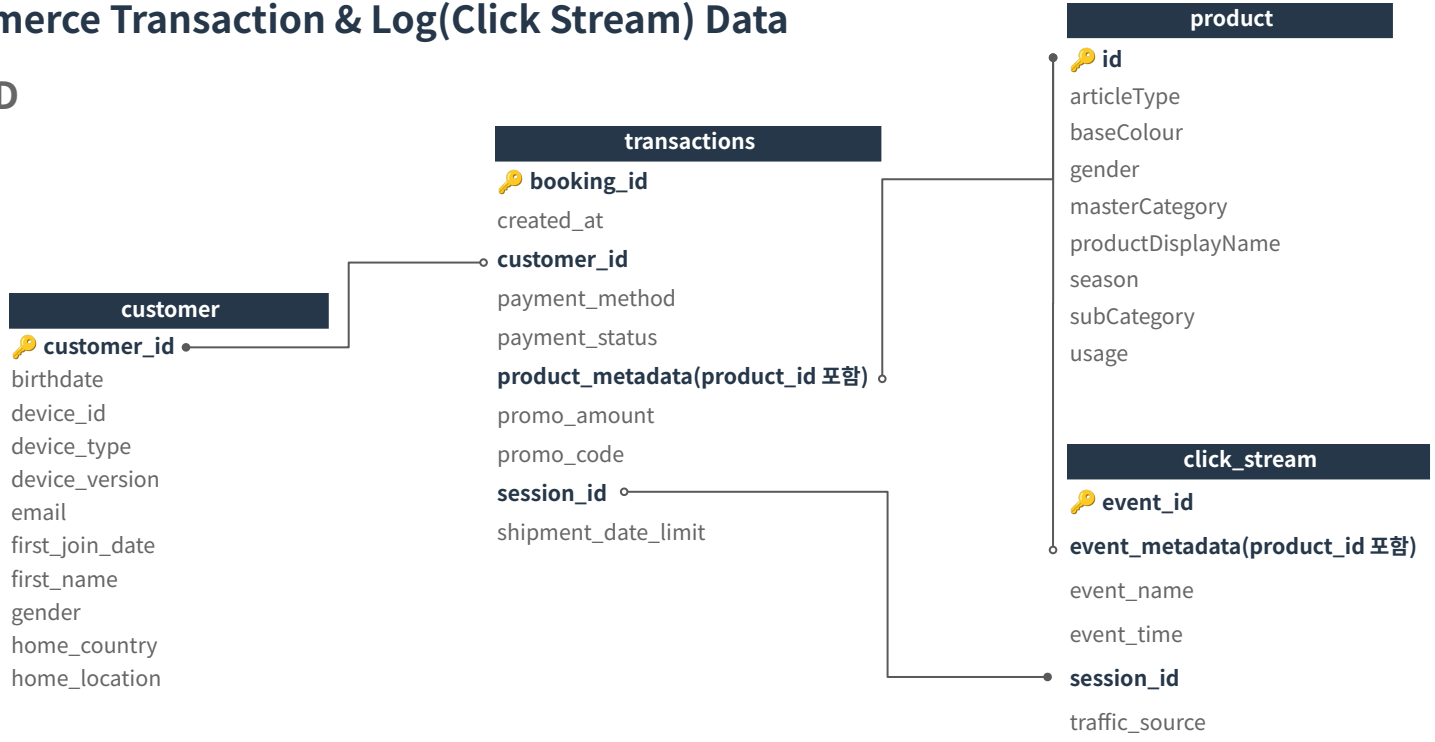

3. 분석할 데이터셋 간단히 살펴보기

E-Commerce Transaction & Log(Click Stream) Data

3.2. Table Description

1) customer (고객)

고객 정보 테이블

컬럼명	설명
customer_id	고객의 고유 ID (Primary Key)
birthdate	고객의 생년월일
device_id	고객이 사용하는 기기의 ID
device_type	고객이 사용하는 기기의 유형
device_version	기기의 소프트웨어 버전
email	고객의 이메일 주소
first_join_date	고객의 최초 가입 날짜
first_name	고객의 이름
gender	고객의 성별
home_country	고객이 거주하는 국가
home_location	고객의 상세 주소 정보

3. 분석할 데이터셋 간단히 살펴보기

E-Commerce Transaction & Log(Click Stream) Data

3.2. Table Description

2) product (상품)

판매되는 상품 정보

컬럼명	설명
id	제품의 고유 ID (Primary Key : product_id)
articleType	제품의 유형 (예: 신발, 의류)
baseColour	제품의 기본 색상
gender	제품의 성별 구분 (남성/여성/공용)
masterCategory	제품의 주요 카테고리
productDisplayName	제품의 표시 이름
season	제품이 출시된 시즌 (예: 겨울, 여름)
subCategory	제품의 하위 카테고리
usage	제품의 용도 (예: 스포츠, 캐주얼)

3. 분석할 데이터셋 간단히 살펴보기

E-Commerce Transaction & Log(Click Stream) Data

3.2. Table Description

3) transactions (거래)

고객이 구매한 제품의 거래 내역

컬럼명	설명
booking_id	거래의 고유 ID (Primary Key)
created_at	거래가 발생한 날짜 및 시간
customer_id	거래를 수행한 고객의 ID (Foreign Key → customer)
payment_method	결제 방식 (예: 카드, 페이팔 등)
payment_status	결제 상태 (예: 완료, 보류 등)
product_metadata	거래된 제품의 상세 정보 (예: `[{'product_id': 54728, 'quantity': 1, 'item_price': 191247}]`)
promo_amount	프로모션 할인 금액
promo_code	적용된 프로모션 코드
session_id	해당 거래의 세션 ID (Foreign Key → click_stream)
shipment_date_limit	배송 예정 기한

3. 분석할 데이터셋 간단히 살펴보기

E-Commerce Transaction & Log(Click Stream) Data

3.2. Table Description

4) click_stream (로그)

고객이 남긴 로그 정보

컬럼명	설명
event_id	이벤트의 고유 ID (Primary Key)
event_metadata	이벤트 관련 추가 정보 (예: `[{'product_id': 54728, 'quantity': 1, 'item_price': 191247}]`)
event_name	이벤트의 이름 (예: 클릭, 구매 등)
event_time	이벤트가 발생한 날짜 및 시간
session_id	해당 이벤트의 세션 ID (Foreign Key → transaction)
traffic_source	트래픽 유입 경로 (예: 광고, 검색)

2차시 과제 안내

<Product Data EDA> 데이터셋으로 그동안 학습했던 것들을 뽐내보자!

1. 자유 형식 EDA 5분 스피치 준비

   PPT, Excel, Jupyter Notebook 등 어떠한 방식이든 OK

   데이터 탐색 과정에서 포커싱한 **분석 주제(아젠다)**를 기반으로 자유롭게 **분석** 진행

   ex. 전체 유저의 구매 관점, 페이지별 이용 관점

2. 발표 진행 방식

   순서는 당일 랜덤으로 지정합니다.

   구성 : 개인별 5~10분 발표 - 전체 토의 시간 5~10분

**과제 마감 기한 : 다음 수업 3시간 이전까지 제출 (환급 기준)*

Q & A

감사합니다!